

Automatización de la Generación de Resúmenes Judiciales mediante Modelos de Lenguaje Natural

Integrantes:

- Fuentes, Tiffany.
- Martinelli, Sofía.

Objetivos preliminares	2
Resultados de los experimentos	2
Datos de la causa	4
Síntesis	6
Sumario	6
Evaluación	6
Dificultades	7
Planificación a lo largo del proyecto	7
Trabajo futuro	8
Conclusión	9
Referencias	9

Ante la necesidad de los empleados del Poder Judicial de la Provincia de Córdoba de redactar manualmente resúmenes de boletines judiciales, y como parte de un esfuerzo continuo por optimizar estos procesos, se ha implementado el uso de modelos de lenguaje natural para automatizar la generación de dichos resúmenes. La técnica seleccionada fue el **prompt engineering**, que permite ajustar las salidas generadas por los modelos a formatos específicos sin requerir un proceso de fine-tuning, lo cual reduce significativamente los costos computacionales y facilita su implementación en entornos prácticos.

Durante esta fase del proyecto, se llevaron a cabo pruebas y evaluaciones comparativas entre modelos multilingües y modelos especializados en español para identificar cuál es más adecuado para generar resúmenes en el ámbito judicial, y si los modelos entrenados específicamente en español logran mayor precisión y coherencia en este dominio.

Objetivos preliminares

En la etapa inicial del proyecto, se plantearon los siguientes objetivos:

1. Desarrollar un prototipo que permita la generación automática de resúmenes de textos judiciales.
2. Comparar el rendimiento de un modelo multilingüe y uno especializado en español para la generación de resúmenes.
3. Analizar la capacidad del **prompt engineering** para generar resúmenes adecuados sin la necesidad de fine-tuning.

A medida que avanzamos, algunas de las hipótesis preliminares fueron revisadas y descartadas en función de los resultados obtenidos. También surgió un nuevo objetivo: optimizar el uso de LLMs (en este caso **ChatGPT**) para condensar los documentos con instrucciones para los sumarios y poder generar un prompt conciso para la generación del mismo.

Resultados de los experimentos

Flan T5, BERT, roBERTa

Para los experimentos realizados con estos tres modelos, implementamos una estrategia común: segmentamos el documento judicial en fragmentos más pequeños y, tras procesar cada uno de ellos, generamos un resumen intermedio con el fin de superar las limitaciones impuestas por el contexto reducido de estos modelos. En cada caso, solicitamos al modelo que produjera un resumen final del documento judicial en su totalidad.

Sin embargo, los resultados obtenidos no fueron satisfactorios. Los tres modelos presentaron incoherencias significativas en sus respuestas, generando información irrelevante o incluso inexistente que no se encontraba en el texto original. Además, dado que roBERTa es un modelo especializado en español, descartamos la hipótesis de que los resúmenes generados

por este modelo serían más precisos que los del modelo multilingüe en lo que respecta al lenguaje legal.

Ante estos problemas de generación de información inexacta, determinamos que estos modelos no son adecuados para nuestros objetivos y los excluimos de futuros experimentos. En consecuencia, se rechaza también otra de las hipótesis formuladas para estos modelos en particular: la posibilidad de mejorar su rendimiento mediante la aplicación de fine-tuning.

Llama 3.1- 8b

Después de experimentar con otros modelos, decidimos centrar nuestros esfuerzos en el modelo Llama 3.1-8b.

El contexto del modelo es lo suficientemente amplio como para permitir el procesamiento completo del documento judicial junto con el prompt, sin necesidad de iterar o agregar resúmenes intermedios, a diferencia de los modelos utilizados anteriormente.

Para evaluar la viabilidad del modelo, seleccionamos un documento judicial específico (2023-04-25 S17 - penal) y solicitamos al modelo que generara un resumen sin proporcionar instrucciones adicionales ni información sobre el formato esperado.

El resumen generado resultó ser extenso e informal, pero contenía exclusivamente información presente en el documento judicial y capturaba adecuadamente los puntos clave del fallo. Esto demostró que el modelo es capaz de producir un resumen fiel al contenido original, aunque presenta oportunidades de mejora en términos de concisión y formalidad.

Basándonos en este primer experimento, decidimos estructurar el proceso de generación de resúmenes en tres partes clave del resumen judicial:

- **Datos de la causa.**
- **Síntesis de la causa.**
- **Sumario.**

Para cada una de estas partes, generamos un prompt separado. Esta segmentación nos permitió incluir ejemplos de respuestas correctas e incorrectas, especificar el formato de salida esperado y adaptar el enfoque según cada tarea. Aunque el modelo tiene un contexto suficientemente amplio, decidimos evitar posibles errores por truncamiento dividiendo el proceso en estas secciones.

A medida que avancemos, evaluaremos si la inclusión de todas las partes en un único prompt mejora los resultados o si es preferible mantener esta segmentación para obtener un control más preciso sobre cada componente del resumen.

Las primeras evaluaciones de los resúmenes generados se llevaron a cabo en varias etapas, combinando métodos cualitativos y cuantitativos.

En primer lugar, realizamos una evaluación manual centrada en aspectos clave como la coherencia del texto, la veracidad de los datos, la adecuación del vocabulario, así como la fluidez y la consistencia semántica del contenido. Estas consideraciones nos permiten asegurar que la salida no solo sea precisa, sino también comprensible y de fácil lectura.

Además, implementamos métricas automáticas de evaluación, como la métrica ROUGE para la sección de "Datos de la Causa", dado que la comparación directa entre el texto original y el resumen es más viable en esta sección.

En el transcurso del proyecto, contaremos con la colaboración de especialistas del Poder Judicial, quienes nos indicarán si los resúmenes logran capturar los puntos más importantes del texto original sin omitir información clave, brindándonos una forma adicional de evaluación.

Datos de la causa

Para extraer los datos clave de la causa judicial, implementamos el siguiente *prompt*:

Extrae solamente los siguientes datos de la causa del texto judicial que sigue. Debes obtener:

1. Fecha
2. Sede
3. Dependencia
4. Autos
5. Resolución
6. Jueces

Formato del resultado (obligatorio):

Fecha: [Fecha]

Sede: [Sede]

Dependencia: [Dependencia]

Autos: [Autos]

Resolución: [Resolución]

Jueces: [Jueces]

Aquí está el texto judicial:

Realizamos varias pruebas modificando el orden en que se presentaba el texto judicial dentro del *prompt* (al inicio o al final), y también resaltando la importancia de términos como "solamente" para enfocar la extracción en los datos solicitados.

El *prompt* que produjo los mejores resultados fue:

Extrae ****solamente**** los siguientes datos de la causa del texto judicial que sigue, en el output solo devuelve la respuesta final. Debes obtener:

1. Sede
2. Dependencia

3. Autos
4. Resolución
5. Fecha
6. Jueces

Formato del resultado (obligatorio):

Sede: [Sede]

Dependencia: [Dependencia]

Autos: [Autos]

Resolución: [Resolución]

Fecha: [Fecha]

Jueces: [Jueces]

Aquí está el texto judicial:

{text}

Resultado generado:

- **Sede:** Córdoba
- **Dependencia:** Cámara Quinta en lo Criminal y Correccional, Sala “C”
- **Autos:** 2018121
- **Resolución:** N° 17
- **Fecha:** 25/04/2023
- **Jueces:** Dra. María Susana Beatriz Blanc Gerzicich de Scapellato y Dr. Oscar Quintana

Resumen original:

- **Sede:** Ciudad de Córdoba
- **Dependencia:** Cámara en lo Criminal y Correccional de Quinta Nominación, Secretaría n.º 9, Sala Unipersonal
- **Autos:** “Gruttadauria, César Daniel y otro p. s. a. homicidio culposo”, expediente n.º 2018121
- **Resolución:** Sentencia n.º 17
- **Fecha:** 25/4/2023
- **Jueza:** María Susana Beatriz Blanc Gerzicich

Métricas ROUGE:

- **ROUGE-1:** Precisión: 0.8158, Recall: 0.5741, F1-score: 0.6739
- **ROUGE-2:** Precisión: 0.4865, Recall: 0.3396, F1-score: 0.4000
- **ROxUGE-L:** Precisión: 0.7105, Recall: 0.5000, F1-score: 0.5870

El resultado fue bastante satisfactorio en términos de precisión y coherencia. Sin embargo, aún falta probar si la inclusión de ejemplos claros, tanto del documento judicial como de los datos de la causa esperados en el resumen, podría mejorar aún más el desempeño del modelo.

Síntesis

En esta sección explicamos los tres enfoques utilizados para generar la síntesis del caso, implementados a través de prompts distintos:

- **Prompt 1:** Fue un prompt genérico, diseñado como base para los otros dos, y que proveía un resumen sin indicaciones específicas.
- **Prompt 2:** Incorporó un ejemplo de una síntesis correcta, en este caso, la síntesis real del fallo en cuestión, con el objetivo de guiar al modelo hacia una respuesta más precisa.
- **Prompt 3:** Además del ejemplo correcto, incluía un ejemplo de una síntesis inadecuada, destacando qué errores se debían evitar en la respuesta.

Cada uno de estos enfoques permitió observar diferencias notables en la precisión y calidad de los resúmenes generados. En particular, se aprecia una mejora notable en los resultados obtenidos con los prompts que incluyen ejemplos, en contraste con el que no utiliza.

Sumario

La generación del sumario ha sido un desafío clave debido a la complejidad inherente a este tipo de texto. Aunque existen instructivos detallados para redactar los sumarios, son documentos muy extensos (creados en 2012), y el propio equipo del Poder Judicial nos indicó que muchos de estos criterios cambian con el tiempo. Esto complica encontrar un enfoque adecuado para comprimir estas instrucciones en un formato manejable para el prompt.

Actualmente, estamos utilizando ChatGPT para procesar estos documentos, extrayendo las instrucciones más relevantes para generar el prompt, pero nos encontramos con múltiples dificultades. La decisión sobre qué información incluir o excluir en el prompt no siempre es clara, ya que el contenido de los instructivos es denso y cambiante. Hay muchas formas de abordar este proceso, y estamos explorando cuál es la más eficiente.

El enfoque utilizado es el mismo que en la síntesis, usando tres prompts distintos, uno sólo con las instrucciones generadas con ayuda de ChatGPT, un segundo prompt incluyendo un ejemplo positivo, y un tercer prompt incluyendo un ejemplo positivo y uno negativo.

Evaluación

El equipo del Poder Judicial realizará una evaluación exhaustiva de los resultados generados por los diferentes prompts. Evaluarán aspectos como coherencia, concisión, exactitud factual y adecuación del lenguaje, utilizando una escala del 1 al 5. Además, proporcionarán comentarios cualitativos sobre la estructura del resumen, indicaciones sobre cómo mejorar el formato (por ejemplo, evitar abreviaciones en nombres), y sugerencias para futuras optimizaciones.

Este feedback nos permitirá no solo elegir el mejor enfoque de generación, sino también refinar los prompts y mejorar los resultados basándonos en sus observaciones. Finalmente, estos comentarios serán la base para iterar sobre los prompts y seguir optimizando el proceso de síntesis y resumen.

Dificultades

Entre las principales dificultades que enfrentamos se incluyen las siguientes:

1. **Limitación de recursos:** Inicialmente, no pudimos correr el modelo con GPU, lo que limitó el número de experimentos que pudimos realizar. Sin embargo, desde hace tres días pudimos acceder a una GPU, lo que ha acelerado significativamente los experimentos.
2. **Evaluación de los resúmenes:** Aunque las métricas automáticas como ROUGE son adecuadas para los datos de la causa, no resultan tan precisas para evaluar síntesis o sumarios. Esto se debe a que el modelo puede generar buenos resultados utilizando palabras diferentes a las del resumen original, afectando negativamente la métrica de ROUGE. Aquí es donde el feedback del equipo experto es esencial para identificar los mejores resúmenes.
3. **Generación de prompts para el sumario:** Crear un buen prompt para los sumarios ha sido complicado debido a la antigüedad de los instructivos y su naturaleza cambiante. Encontrar una fórmula que resuma estas instrucciones de manera eficiente es un reto que seguimos enfrentando.

Planificación a lo largo del proyecto

A pesar de que surgieron algunas dificultades a lo largo del desarrollo del proyecto, la planificación inicial fue bastante precisa.

En un principio, habíamos proyectado alcanzar avances significativos y obtener resultados preliminares para la última semana de octubre, incluyendo un análisis comparativo entre modelos y una autoevaluación de los resúmenes generados. Si bien logramos cumplir con los plazos estimados, uno de los aspectos que no cumplió con nuestras expectativas fue la cantidad de pruebas realizadas durante el período de experimentación. Esto se debió a las dificultades técnicas previamente mencionadas, particularmente la imposibilidad de ejecutar los modelos con GPU. En consecuencia, aunque respetamos los tiempos planificados, no fue posible realizar experimentos con la totalidad o una gran cantidad de archivos.

Un cambio significativo respecto a la planificación inicial, realizada al comienzo del cuatrimestre, fue la decisión de descartar el fine-tuning previsto para las últimas semanas. En su lugar, optamos por priorizar la corrección y el refinamiento de los prompts basándonos en evaluaciones de expertos. Sin embargo, durante las últimas semanas no recibimos las correcciones ni evaluaciones esperadas por parte del equipo del Poder Judicial, lo que generó

limitaciones para avanzar con mayor precisión. Esto nos llevó a una situación de incertidumbre respecto a la conveniencia de seguir adelante sin contar con indicadores claros sobre la calidad y corrección de nuestro trabajo.

Otro aspecto relevante de la planificación fue el feedback recibido al entregar el informe preliminar, el cual incluyó varias sugerencias útiles por parte de nuestros compañeros. Dado que aún nos encontrábamos en una etapa de exploración, muchos de sus comentarios nos permitieron identificar aspectos que no habíamos considerado en profundidad, como los métodos más adecuados para generar los prompts, las estrategias para evaluar los modelos y las condiciones bajo las cuales sería necesario realizar fine-tuning. Este intercambio fue particularmente valioso, ya que nos ayudó a replantear y enriquecer nuestro enfoque de trabajo.

Trabajo futuro

Considerando un equipo de cinco personas trabajando durante un año a tiempo completo, las siguientes líneas de investigación y desarrollo podrían implementarse para continuar avanzando en este proyecto:

1. Implementación de un pipeline híbrido con múltiples LLMs:

Diseñar un flujo de trabajo en el que un modelo de lenguaje distinto a LLaMA genere prompts optimizados para resumir documentos judiciales. Estos prompts se pasarían, junto con el documento original, al modelo LLaMA para generar los resúmenes. Este enfoque podría mejorar la calidad y especificidad de los resúmenes generados.

2. Creación de un evaluador automático para resúmenes:

Desarrollar un sistema automatizado, basado en un modelo de lenguaje, que evalúe los resúmenes generados. Este evaluador analizará aspectos como coherencia, factibilidad, precisión y relevancia, basándose en los criterios definidos durante la evaluación manual realizada en este estudio.

3. Uso de LLMs comerciales y APIs de pago:

Explorar el uso de modelos de lenguaje comerciales, como Claude o Gemini, que ofrecen soluciones optimizadas a través de sus APIs. Estos modelos podrían proporcionar resúmenes de mayor calidad sin la necesidad de disponer de hardware avanzado, reduciendo significativamente la carga computacional.

4. Fine-tuning de LLaMA para resúmenes judiciales:

Realizar un ajuste fino del modelo LLaMA utilizando un conjunto de datos especializado en textos judiciales. Este enfoque permitiría que el modelo se adapte mejor al lenguaje y

las estructuras legales específicas, mejorando así la precisión y la utilidad de los resúmenes.

Estas propuestas, aunque relativamente simples de implementar a nivel de código, requieren un acceso considerable a recursos de hardware para llevar a cabo entrenamientos y pruebas a gran escala. Esto subraya la importancia de contar con infraestructura adecuada para seguir explorando las capacidades de los modelos de lenguaje en el ámbito judicial.

Conclusión

En este trabajo, se abordó la automatización de la generación de resúmenes judiciales mediante modelos de lenguaje natural, respondiendo a la necesidad de optimizar los procesos manuales llevados a cabo en el Poder Judicial de Córdoba.

Los objetivos iniciales incluían el desarrollo de un prototipo funcional, la comparación entre modelos multilingües y especializados en español, y la evaluación de la técnica de prompt engineering como alternativa eficiente al fine-tuning.

A lo largo del proyecto, si bien los modelos iniciales (Flan-T5, BERT y roBERTa) no lograron cumplir con las expectativas en términos de coherencia y precisión, el modelo LLaMA 3.1-8b demostró ser una herramienta prometedora. Este modelo, con un contexto más amplio, permitió segmentar y estructurar los resúmenes en tres partes clave: datos de la causa, síntesis y sumario.

Si bien los resultados alcanzados son satisfactorios, es importante destacar que los resúmenes generados no reemplazarán el trabajo humano debido a la complejidad inherente al lenguaje jurídico y a las variaciones en los criterios de redacción. No obstante, como herramienta de apoyo, el sistema tiene un gran potencial para facilitar y agilizar la tarea de los profesionales judiciales, especialmente si se incorporan las correcciones y evaluaciones de expertos.

En conclusión, aunque existen desafíos técnicos y conceptuales, la automatización mediante modelos de lenguaje natural representa un avance significativo en la optimización de procesos judiciales, posicionándose como una herramienta valiosa para el futuro.

Referencias

- Kojima, T., Gu, S. S., Reid, M., Matsuo, Y., & Iwasawa, Y. (2022). Large language models are zero-shot reasoners. Proceedings of the 36th International Conference on Neural Information Processing Systems (NeurIPS 2022).
- Liu, Y., & Lapata, M. (2019). Text Summarization with Pretrained Encoders. Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP), 3730-3740.

- Reynolds, L., & McDonell, K. (2021). Prompt Programming for Large Language Models: Beyond the Few-Shot Paradigm. Extended Abstracts of the 2021 CHI Conference on Human Factors in Computing Systems.